Université Nationale des Sciences, Technologies, Ingénierie et Mathématiques
École Nationale Supérieure de Génie Mathématique et Modélisation

Prédiction des Coûts de l'Assurance Maladie

Régression Linéaire Multiple avec Résolution des Problèmes liés aux Hypothèses

Charmant Balogoun Haboud Boukari

Sous la supervision de:
Dr Nicodème Atchade

Année académique 2025–2026

Plan

1. Introduction
2. Matériels et Méthodes
3. Résultats et Discussion
4. Conclusion
5. Références

Contexte et Hypothèses

- Aux États-Unis, la tarification des primes d'assurance maladie repose sur l'évaluation du risque individuel. (Diehr et al.)
- Les dépenses de santé représentent un enjeu financier majeur.
- La régression linéaire permet d'isoler l'effet de chaque facteur.

(H1) L'âge a un effet positif sur les charges médicales

(H2) Un indice de masse corporelle élevé augmente les charges

(H3) Le tabagisme et l'alcoolisme influencent fortement les charges

Objectifs

Question de recherche

Peut-on prédire avec précision les coûts de l'assurance maladie avec un regression linéaire ?

Objectif général : Construire un modèle linéaire performant et valide.

Objectifs spécifiques :

- Analyse exploratoire des données
- Estimation du modèle et tests des hypothéses de Gauss-Markov
- Correction des violations détectées
- Sélection du meilleur modèle

Données

Source

Jeu de données de frais médicaux américains
Medical Cost Personal Datasets (**insurance.csv**) disponible sur Kaggle
1 338 observations , 7 variables

Table 1 – Variables du jeu de données

Variable	Type
`age`	Numérique
`sex`	Catégorielle
`bmi`	Numérique
`children`	Numérique
`smoker`	Catégorielle
`region`	Catégorielle
`charges`	**Variable cible (Y)**

Outils

R 4.5.3 : `tidyverse`, `corrplot`, `car`, `lmtest`, `ggplot2`

Modèle générique

Le modèle de régression linéaire multiple s'écrit :

$$Y_i = \beta_0 + \sum_{j=1}^{p} \beta_j X_{ij} + \varepsilon_i \tag{1}$$

Estimation des paramètres par la méthode des moindres carrés(MCO) :

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \tag{2}$$

Pour notre étude :

$$\begin{aligned} \text{charges}_i = \beta_0 &+ \beta_1\, \text{age}_i + \beta_2\, \text{sex}_i + \beta_3\, \text{bmi}_i \\ &+ \beta_4\, \text{children}_i + \beta_5\, \text{smoker}_i + \beta_6\, \text{region}_i + \varepsilon_i \end{aligned} \tag{3}$$

Hypothéses de validation

Table 2 – Hypothèses de Gauss-Markov

	Hypothèse	Test utilisé	Seuil
(a)	$\mathbb{E}(\varepsilon) = 0$	Moyenne des résidus	≈ 0
(b)	Homoscédasticité	Breusch-Pagan, Goldfeld-Quandt	$\alpha = 5\%$
(c)	Absence de multicolinéarité	VIF	< 5
(d)	Indépendance des erreurs	Durbin-Watson	$\alpha = 5\%$
(e)	Normalité des résidus	Shapiro-Wilk, Q-Q Plot	$\alpha = 5\%$
(f)	Linéarité	Rainbow Test	$\alpha = 5\%$

Validation de l'estimateur MCO

Le MCO est **BLUE** (Best Linear Unbiased Estimator) si ces hypothèses sont vérifiées.

Critéres de sélection

Table 3 – Critères pour la sélection et la comparaison des modèles

Critère	**Interprétation**
AIC	Plus faible = meilleur modèle (équilibre biais-variance)
BIC	Plus faible = meilleur modèle (préféré pour grands échantillons)
RMSE	Plus faible = meilleure précision
MAE	Plus faible = meilleure précision (moins sensible aux outliers)
MAPE	Plus faible = meilleure précision relative (%)
R^2 ajusté	Plus élevé = meilleur ajustement (comparable entre modèles)

Ces critères seront calculés sur l'échantillon d'entraînement (AIC, BIC, R^2 ajusté) et sur l'échantillon de test (RMSE, MAE, MAPE) afin d'évaluer à la fois la qualité d'ajustement et la capacité prédictive des modèles.

Stratégie de modélisation

1. Analyse exploratoire des données
2. Partition des données : 80% entraînement / 20% test
3. Estimation du modèle et tests des hypothéses de Gauss-Markov
4. Corrections des violations d'hypothèses
5. Sélection du meilleur modèle basée sur les métriques

Statistiques descriptives

Table 4 – Statistiques descriptives du jeu de données « Medical Cost Personal »

Variable	**Min**	**1er quartile**	**Médiane**	**Moyenne**	**3e quartile**	**Max**
age	18.00	27.00	39.00	39.21	51.00	64.00
bmi	15.96	26.30	30.40	30.66	34.69	53.13
children	0.00	0.00	1.00	1.095	2.00	5.00
charges	1 122	4 740	9 382	13 270	16 640	63 770

Variable qualitative	**Effectifs**
sex (female / male)	662 / 676
smoker (no / yes)	1 064 / 274
region	northeast : 324, northwest : 325, southeast : 364, southwest : 325

Distribution des charges Y

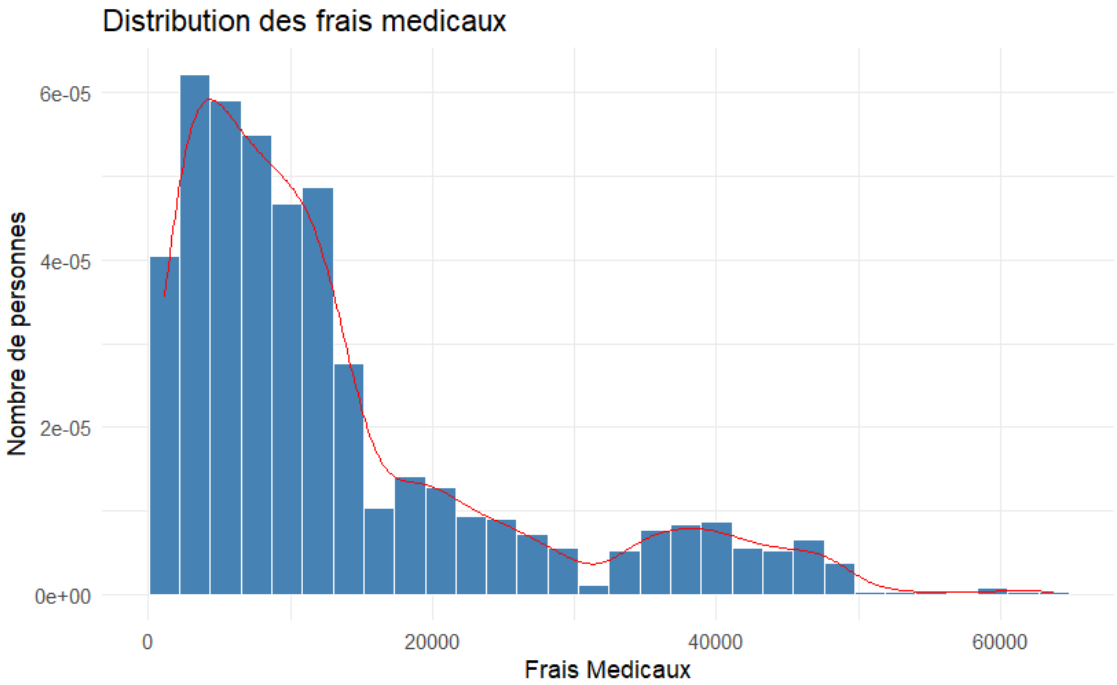


Figure 1. Distribution des charges.

Observations clés :

- Asymétrie vers la droite
- Minorité à coûts très élevés ⇒ valeurs influentes potentielles

⇒ Transformation de Y envisagée

Variables quantitatives et corrélations

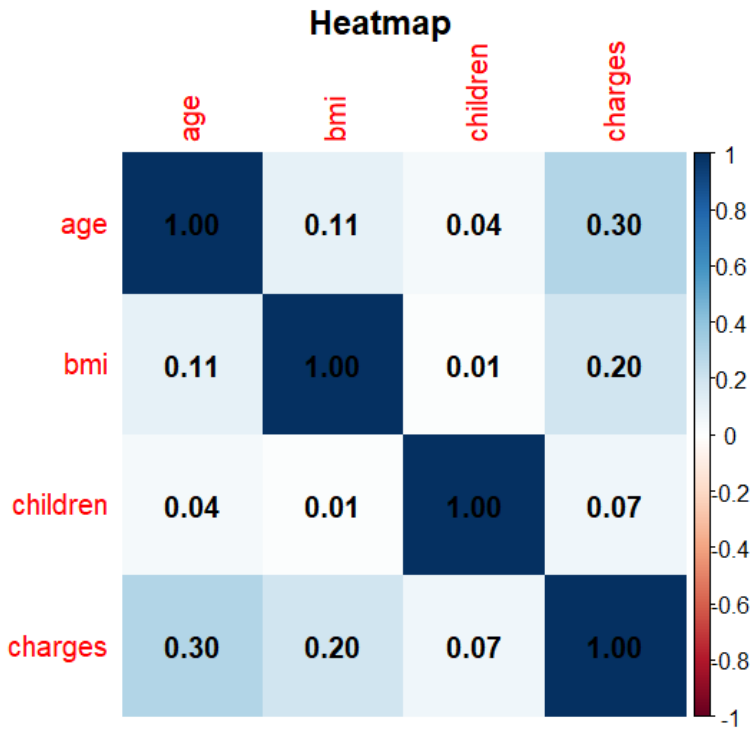


Figure 2. Heatmap des corrélations.

Corrélations avec `charges` :

- `age` : $r = 0{,}30$ Impact modéré
- `bmi` : $r = 0{,}20$ Impact modéré
- `children` : $r = 0{,}07$ Impact faible

Entre prédicteurs :

- Toutes les corrélations sont $< 0{,}15$
- Pas de redondance entre variables $\Rightarrow$ la multicolinéarité est peu probable.

Variables qualitatives

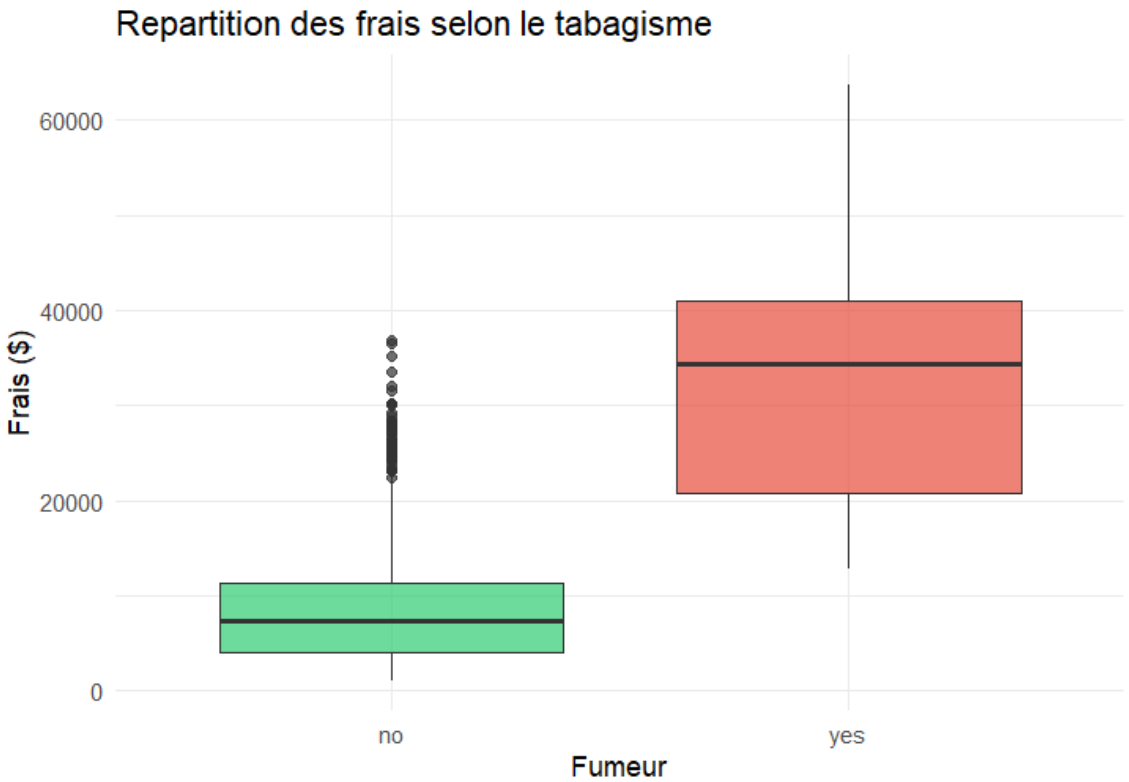


Figure 3. Frais selon le tabagisme.

Résultats ANOVA :

- Tabagisme : $F = 2178$, $p < 2{,}2 \times 10^{-16}$***
- Région : $p = 0{,}031$ *
- Sexe : $p = 0{,}036$ *

Interaction

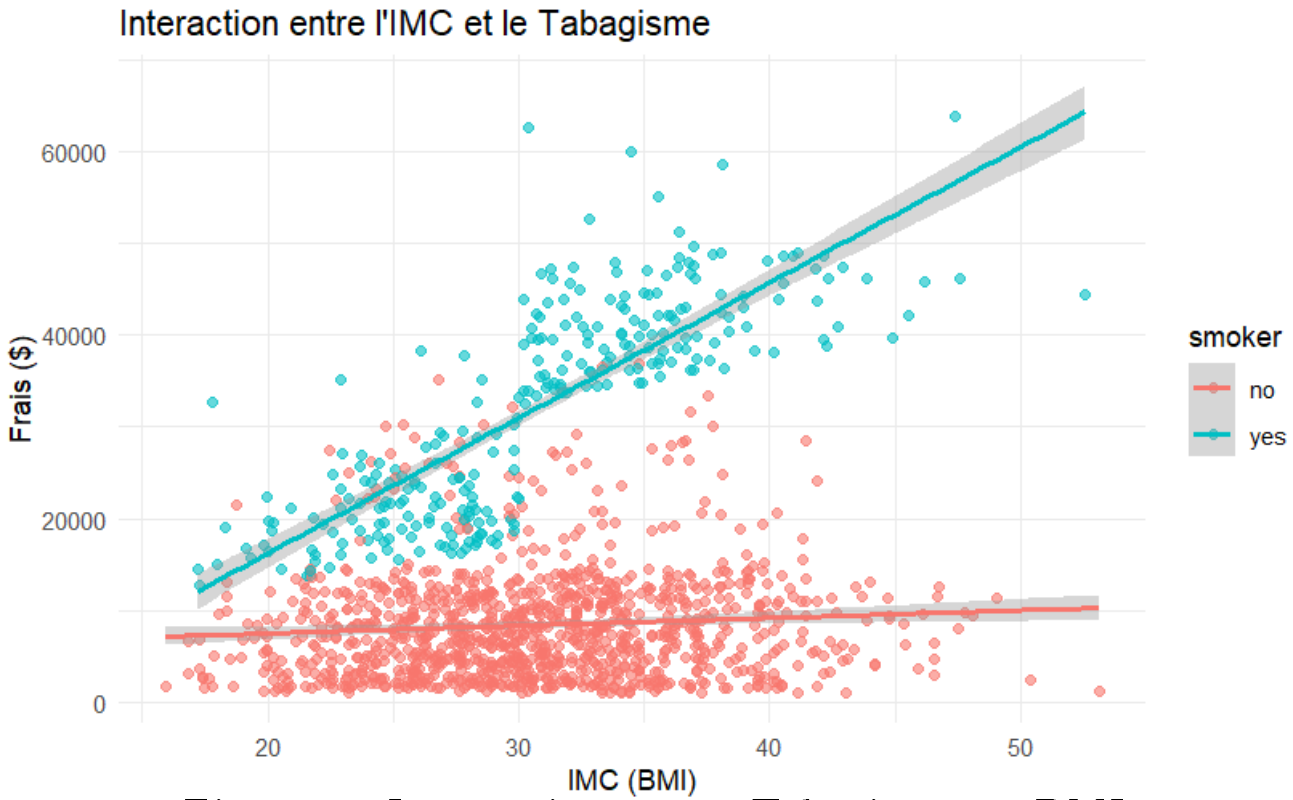


Figure 4. Interaction entre Tabagisme et BMI.

Interaction BMI × Tabac :

- Non-fumeurs : pente BMI ≈ 0
- Fumeurs : pente BMI très élevée

$\Rightarrow$ terme d'interaction à inclure

Modèle linéaire de base

$$\begin{aligned}\widehat{\text{charges}}_i = &-11\,938 + 257\,\text{age}_i + 339\,\text{bmi}_i + 475\,\text{children}_i \\ &+ 23\,848\,\text{smokeryes}_i - 353\,\text{sexmale}_i - 1\,036\,\text{regionNW}_i \\ &- 960\,\text{regionSE}_i - 1\,193\,\text{regionSW}_i \end{aligned} \tag{4}$$

Qualité globale :

- $R^2 = 0{,}7509$
  $R^2_{\text{adj}} = 0{,}749$
- p-value globale $< 2{,}2 \times 10^{-16}$

Coefficients significatifs :

- Les coefficients de `age`, `bmi`, `children` et `smokeryes` sont tous significatifs ($p < 0{,}05$)
- Les coefficients de `sexmale`, `regionNW`, `regionSE` et `regionSW` sont non significatifs ($p > 0{,}05$).

Diagnostic des résidus

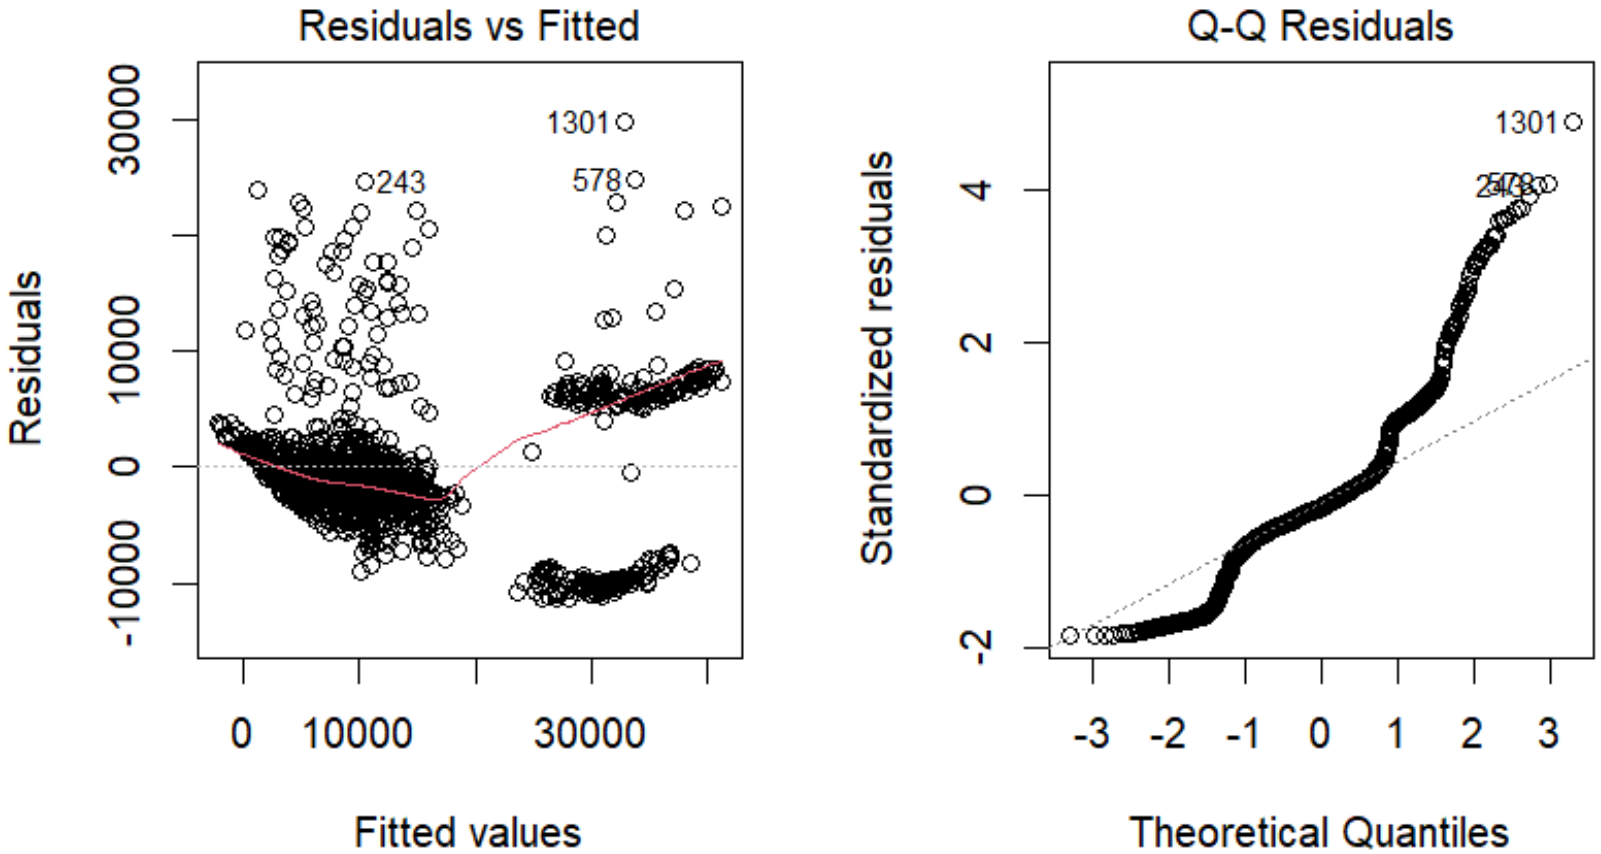


Figure 5 : Graphiques de diagnostic des résidus du modèle linéaire de base.

Validation des hypothéses

Table 5 – Tests de validation des hypothèses de Gauss-Markov pour le modèle linéaire de base

	Hypothèse	**Test / Stat.**	**Conclusion**
(a)	$\mathbb{E}(\varepsilon) = 0$	$\approx 10^{-14}$	**V.**
(b)	Homoscédasticité	BP : $p < 2{,}2e{-}16$	**R.**
(c)	Non-multicolinéarité	VIF ≈ 1	**V.**
(d)	Indépendance des erreurs	DW : $p = 0{,}594$	**V.**
(e)	Normalité des résidus	SW : $p < 2{,}2e{-}16$	**R.**
(f)	Linéarité	Rainbow : $p = 0{,}058$	**V.**

Bilan

Deux violations majeures : hétéroscédasticité et non-normalité des résidus.
$\Rightarrow$ Les tests t et F sont potentiellement biaisés. Des corrections s'imposent.

Corrections des violations

Table 6 – Méthodes de correction pour l'hétéroscédasticité et la non-normalité

Méthode	**Violation ciblée**	**BP p-val**	**SW p-val**
Transf. $\ln(Y)$	Hétéroscéd. + normalité	$1{,}34 \times 10^{-12}$	$< 2{,}2 \times 10^{-16}$
Box-Cox ($\lambda = 0{,}14$)	Normalité	$1{,}11 \times 10^{-7}$	$< 2{,}2 \times 10^{-16}$
WLS	Hétéroscédasticité	1,00 **V.**	$< 2{,}2 \times 10^{-16}$
White (HC3)	Hétéroscédasticité	$< 2{,}2 \times 10^{-16}$	$< 2{,}2 \times 10^{-16}$

Constat

Toutes ces approches corrigent partiellement l'hétéroscédasticité mais échouent à normaliser les résidus. La non-normalité persistante : elle reflète l'hétérogénéité intrinsèque des coûts de santé, dont la distribution est reconnue comme non-gaussienne (Manning and Mullahy, Duan).

Suppression d'outliers

Procédure :

- Résidus studentisés $|r_i^*| > 2{,}5$
- Suppression de 60 observations environ
- Modèle ré-estimé (`modele_unique_clean`)

Résultats :

- $R^2_{\text{adj}} = 0{,}971$
- SW : $p = 7{,}5 \times 10^{-42}$ – non-normalité persiste

La suppression des outliers n'améliore pas significativement la normalité.

Raison du rejet

La suppression d'outliers revient à exclure des profils réels (fumeurs obèses à coûts élevés) qui sont précisément les cas les plus importants à prédire pour l'assureur (Duan). De plus, le $R^2 = 0{,}971$ est artificiellement gonflé par la réduction de la variance de l'échantillon.

Terme d'interaction

Motivation : l'analyse exploratoire et la littérature (Flegal et al., Bhattacharya and Bundorf) montrent que l'effet de l'obésité sur les coûts est conditionnel au statut tabagique.

Modèle avec interaction

$$\begin{aligned}\widehat{\text{charges}}_i = &-1\,813 + 261\,\text{age}_i + 130\,\texttt{is_obese}_i + 13\,470\,\text{smokeryes}_i \\ &+ 495\,\text{children}_i - 410\,\text{sexmale}_i - 254\,\text{regionnw}_i \\ &- 470\,\text{regionse}_i - 1\,172\,\text{regionsw}_i + \mathbf{20\,006}\,(\texttt{is_obese} \times \texttt{smokeryes})_i \end{aligned} \quad (5)$$

Interprétation :

- Fumeur non-obèse : $+13\,470\,\$$
- Fumeur obèse : $+13\,470 + 130 + 20\,006 = +33\,606\,\$$
- L'obésité multiplie quasiment par 2,5 l'effet du tabac

Progrès remarquable

Cette approche **résout l'hétéroscédasticité** et améliore fortement le pouvoir explicatif : $R^2_{\text{adj}} = 0{,}864$.

Diagnostic des résidus améliorés

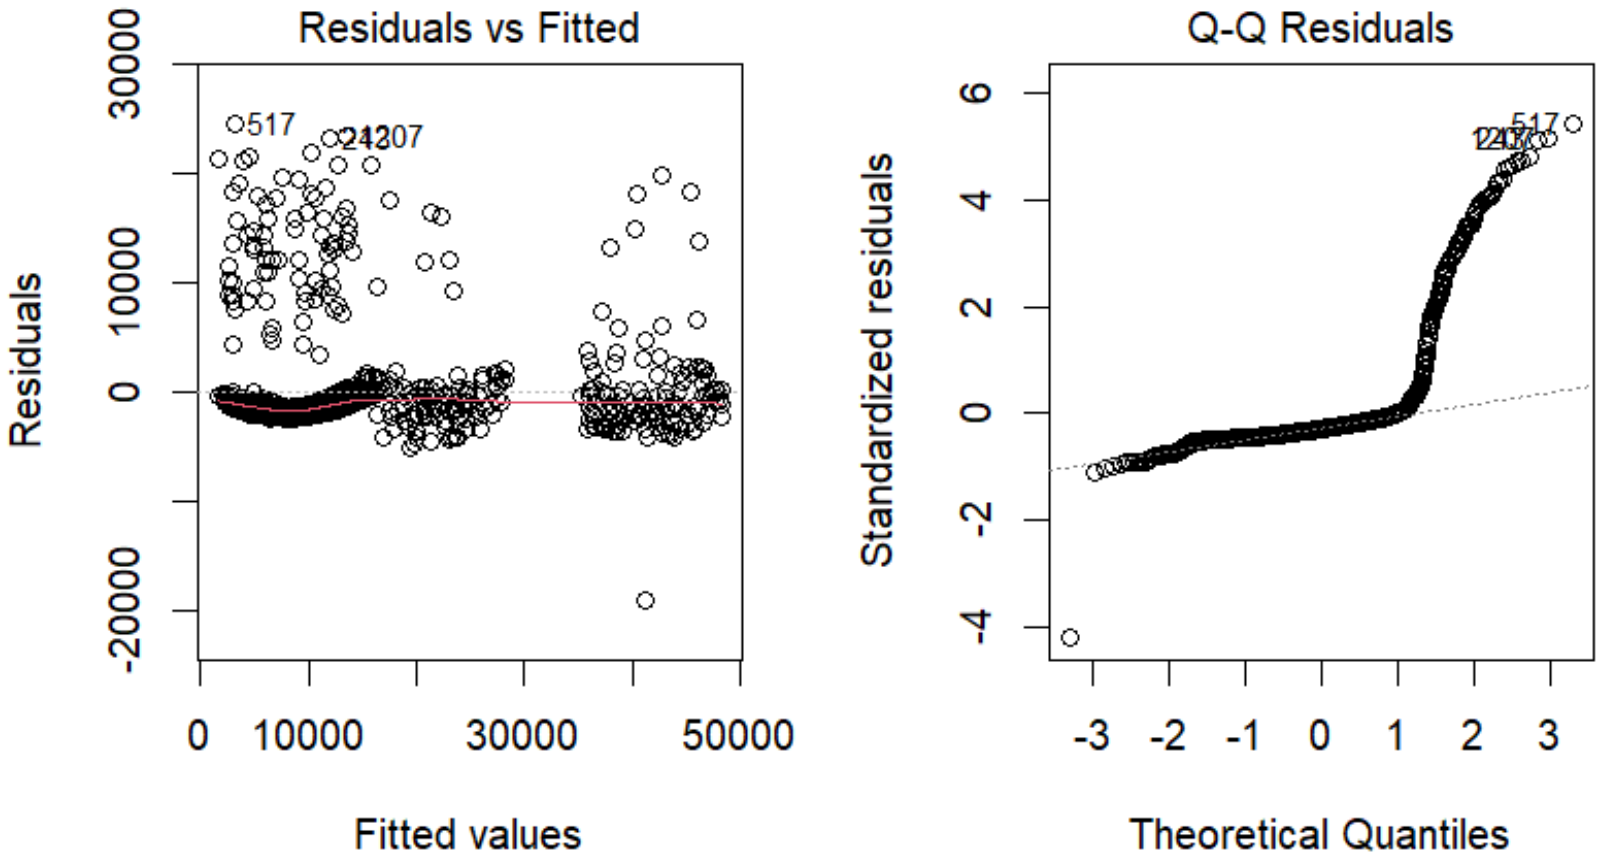


Figure 6 : Graphiques de diagnostic des résidus après introduction du terme d'interaction.

Modèle sélectionné

$$\begin{aligned}\widehat{\text{charges}}_i = &-1\,813 + 261\,\text{age}_i + 130\,\texttt{is_obese}_i + 13\,470\,\text{smokeryes}_i \\ &+ 495\,\text{children}_i - 410\,\text{sexmale}_i - 254\,\text{regionnw}_i \\ &- 470\,\text{regionse}_i - 1\,172\,\text{regionsw}_i + 20\,006\,(\texttt{is_obese} \times \texttt{smokeryes})_i \end{aligned} \quad (6)$$

$R^2_{\text{adj}} = 0{,}864 \quad \text{RSE} = 4\,544\,\$ \quad p_{\text{global}} < 2{,}2 \times 10^{-16}$

Interprétations clés :

- **Âge** : $+261\,\$/an$
- **Tabagisme seul** : $+13\,470\,\$$ (effet major)
- **Obésité + tabac** : $+33\,606\,\$$ (effet synergique)
- **Enfant** : $+495\,\$$ par enfant
- L'obésité seule n'a d'effet que chez les fumeurs

Validité et cohérence des résultats

Non-normalité persistante des résidus

- Non-normalité structurelle des données de santé (Manning and Mullahy)
- Théorème Central Limite valide pour $n = 1\,070$ observations (White)
- Shapiro-Wilk trop sensible pour grands échantillons (Royston)

Alignement avec la littérature

- **Tabagisme majeur :** facteur principal de surcoût médical (Hodgson).
- **Interaction obésité-tabac :** l'effet synergique confirmé (Bhattacharya and Bundorf).
- **Âge linéaire :** augmentation régulière (Diehr et al.).

Limites opérationnelles

- Données américaines de 2018 – contexte spécifique
- Absence de facteurs comportementaux détaillés

Les résultats obtenus apportent une réponse affirmative à notre question de départ. Le modèle retenu — une régression linéaire multiple intégrant un terme d'interaction entre l'obésité et le tabagisme — atteint un coefficient de détermination ajusté de 0,864 et un RSE de 4 544 sur l'échantillon d'entraînement, démontrant une capacité prédictive solide à partir des seules caractéristiques socio-démographiques et comportementales des assurés.

Approches futures : régression quantile, apprentissage supervisé.

Références bibliographiques

J. Bhattacharya and M. K. Bundorf. The incidence of the healthcare costs of obesity. *Journal of Health Economics*, 28(3) :649–658, 2009.

P. Diehr et al. Including deaths when measuring health care utilization over time. *Medical Care*, 37(4) : AS136–AS145, 1999. Supplement.

N. Duan. Smearing estimate : A nonparametric retransformation method. *Journal of the American Statistical Association*, 78(383) :605–610, 1983.

K. M. Flegal et al. Excess deaths associated with underweight, overweight, and obesity. *JAMA*, 293(15) : 1861–1867, 2005.

T. A. Hodgson. Cigarette smoking and lifetime medical expenditures. *The Milbank Quarterly*, 70(1) :81–125, 1992.

W. G. Manning and J. Mullahy. Estimating log models : To transform or not to transform ? *Journal of Health Economics*, 20(4) :461–494, 2001.

P. Royston. Approximating the Shapiro-Wilk W-test for non-normality. *Statistics and Computing*, 2(3) :117–119, 1992.

H. White. A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4) :817–838, 1980.

Merci !

Questions ?